

ReDataX

M1: Multiscale Model

Egor Vasilev

Содержание

1	Роль модели и проверяемая гипотеза	2
2	Мотивация многомасштабного описания	2
3	Данные и поле направленного потока	3
4	Признаки модели	3
5	Целевая переменная	4
6	Статистическая модель и обучение	5
7	Временная проверка и метрики	5
8	Результаты сравнения с M0	5
9	Ограничения и воспроизводимость	6

1 Роль модели и проверяемая гипотеза

M1 является первой надстройкой над базовой M0. Если M0 описывает поток одним единственным масштабом, M1 делает это уже на нескольких. Введем

Определение 1.1. Информационным множеством $\mathcal{I}_t$ будем называть совокупность данных, доступных не позднее момента принятия решения, при этом признак считается допустимым, если он измерим относительно $\mathcal{I}_t$.

Тогда, для сравнения двух моделей единственным отличием как раз является информационное множество, все прочие, а именно — целевая переменная, горизонт, алгоритм классификации, временные разбиения и метрики — остаются неизменными. Таким образом, формулируется

Гипотеза 1.1. Многомасштабное (мультимасштабное) рассмотрение направленного потока одного рынка содержит более содержательную информацию о его состоянии, чем одномасштабное приближение. Иными словами, при одинаковой метке $Y_{t,H}$ и едином построении признаков,

$$\mathbb{P}(Y_{t,H} = 1 \mid X_t^{(1)}) \neq \mathbb{P}(Y_{t,H} = 1 \mid X_t^{(0)}),$$

где $X_t^{(0)}$ и $X_t^{(1)}$ — признаки M0 и M1 соответственно. Критерием принятия M1 является положительная разность средних по дням значений Average Precision.

2 Мотивация многомасштабного описания

Одно и то же значение дисбаланса, измеренное на единственном окне, может отвечать разным состояниям рынка: краткому импульсу на нейтральном длинном фоне, устойчивому однонаправленному потоку на всех масштабах, развороту потока с разными знаками на коротком и длинном окнах, единичной крупной сделке, не поддержанной остальным потоком. Модель M0 не различает эти ситуации, если некоторая характеристика на выбранном масштабе совпадает. M1 в свою очередь описывает текущее состояние рынка вектором значений одной и той же характеристики, вычисленной на семействе вложенных окон.

Определение 2.1. Семейством масштабов $\mathcal{B}$ называется упорядоченное множество временных интервалов, выбранных для построения признаков.

Определение 2.2. Пусть задано семейство масштабов $\mathcal{B} = \{\tau_1, \tau_2, \dots, \tau_K\}$ и некоторая характеристика потока $f^{(\tau)}$, вычисленная на окне $(t - \tau, t]$. Тогда профилем характеристики f в момент t называется вектор

$$\mathbf{f}_t = (f_t^{(\tau_1)}, f_t^{(\tau_2)}, \dots, f_t^{(\tau_K)})^\top.$$

К примеру, использование профиля дисбаланса объёмов позволяет отличить шумовой всплеск от формирующегося тренда и уловить смену знака потока раньше, чем она станет заметной на единственном окне. Короткие масштабы улавливают быстрые изменения, длинные — накопленный фон. Здесь уместна аналогия со статистической физикой: в системе многих частиц существуют флуктуации двух типов — коротковолновые и длинноволновые. Первые проявляются на малых расстояниях и не несут колоссальных изменений, вторые же могут внести колоссальные изменения, например, струя воды из крана в какой то момент начинает рваться из-за длинноволновых флуктуаций.

3 Данные и поле направленного потока

Исходными событиями являются агрегированные сделки Binance Spot (`aggTrades`). Каждая сделка k характеризуется ценой, номиналом n_k (в котируемой валюте), временем и флагом m со значениями `true`, если покупатель был мейкером, `false` иначе. Парсер ReDataX определяет знак агрессивной стороны ε_k по правилу

$$\varepsilon_k = \begin{cases} +1, & m=\text{false} \quad (\text{агрессивная покупка базового актива}), \\ -1, & m=\text{true} \quad (\text{агрессивная продажа базового актива}). \end{cases}$$

Определение 3.1. Для произвольного набора событий W подписанным потоком будем называть величину

$$\phi(W) = \frac{\sum_{k \in W} \varepsilon_k n_k}{\sum_{k \in W} n_k},$$

где n_k — номинал сделки в котируемой валюте. При положительном знаменателе $\phi(W) \in [-1, 1]$.

На каждом масштабе τ_i все сделки сначала агрегируются по целым секундам. Для целевого рынка A в каждую завершённую секунду t вычисляются объёмы агрессивных покупок $V_A^+(t)$ и продаж $V_A^-(t)$, после чего секундный дисбаланс равен

$$\phi_A(t) = \begin{cases} \frac{V_A^+(t) - V_A^-(t)}{V_A^+(t) + V_A^-(t)}, & V_A^+(t) + V_A^-(t) > 0, \\ 0, & \text{в отсутствие сделок.} \end{cases}$$

Для каждого масштаба $B \in \mathcal{B}$ вводится сглаженное поле

$$\bar{\phi}_A^{(B)}(t) = \frac{1}{B} \sum_{u=0}^{B-1} \phi_A(t-u),$$

представляющее собой скользящее среднее по календарным секундам, включая текущую завершённую секунду. Секунды без сделок сохраняются в знаменателе B , уменьшая среднюю амплитуду поля в периоды низкой активности.

4 Признаки модели

Из многомасштабного поля $\bar{\phi}_A^{(B)}(t)$ и знака текущего потока $d_A(t) = \text{sign } \phi_A(t)$ формируются четыре группы признаков.

Определение 4.1. Для масштаба B согласованным потоком называется величина

$$h_{A,B}(t) = d_A(t) \bar{\phi}_A^{(B)}(t).$$

Положительное значение означает сонаправленность исторического потока на данном масштабе с текущим суммарным направлением.

Определение 4.2. Амплитудой дисбаланса называется модуль сглаженного поля

$$r_{A,B}(t) = |\bar{\phi}_A^{(B)}(t)|,$$

По смыслу — это абсолютная величина несбалансированности потока.

Чтобы линейная модель могла различать слабые и сильные дисбалансы независимо от их знака, вводятся чётные степени сглаженного поля:

$$a_{A,B}(t) = (\bar{\phi}_A^{(B)}(t))^2, \quad b_{A,B}(t) = (\bar{\phi}_A^{(B)}(t))^4.$$

В теории критического поведения и квантовой теории поля существует модель, называемая ϕ^4 :

$$\mathcal{H} = \int d^D x \left[\frac{1}{2} (\nabla \phi)^2 + \frac{1}{2} m^2 \phi^2 + \frac{\lambda}{4!} \phi^4 \right] \quad (1)$$

- это гамильтониан, описывающий поведение системы при приближении к точке фазового перехода. При этом квадратичный член ϕ^2 отвечает за энергетическую стоимость флуктуаций поля, а член ϕ^4 описывает самодействие и определяет характер фазового перехода. Отсюда появляется соображение рассматривать чётные степени дисбаланса.

Наконец, абсолютный размер секунды фиксируется логарифмом совокупного номинала:

$$\ell_A(t) = \log(1 + V_A^+(t) + V_A^-(t)).$$

Итоговый вектор признаков для каждого допустимого момента t имеет вид

$$X^{\text{M1}}(t) = \left[\ell_A(t), \{h_{A,B}(t)\}_{B \in \mathcal{B}}, \{r_{A,B}(t)\}_{B \in \mathcal{B}}, \{a_{A,B}(t)\}_{B \in \mathcal{B}}, \{b_{A,B}(t)\}_{B \in \mathcal{B}} \right]^\top,$$

и его размерность равна

$$\dim X^{\text{M1}} = 1 + 4|\mathcal{B}| = 29 \quad (2)$$

5 Целевая переменная

Для секундной реализации пусть $P_A(t)$ — средневзвешенная по объёму цена завершённой секунды t . Знаковый маркаут на горизонте H в базисных пунктах определяется как

$$m_{A,H}(t) = 10^4 d_A(t) \frac{P_A(t+H) - P_A(t)}{P_A(t)},$$

где $d_A(t) = \text{sign } \phi_A(t)$. Бинарная метка принимает значение 1 при положительном маркауте:

$$Y_{A,H}(t) = \mathbb{1}\{m_{A,H}(t) > 0\}.$$

Наблюдение считается допустимым, только если целевой рынок активен в секунду t , $d_A(t) \neq 0$ и VWAP существует ровно в моменты t и $t+H$. Перенос последней цены вперёд не применяется. В финальном межрыночном эксперименте зафиксирован горизонт $H = 5$ с.

Положительный маркаут означает движение цены в направлении текущего суммарного потока, что создаёт риск для поставщика ликвидности, принявшего противоположную сторону.

6 Статистическая модель и обучение

Модель M1, как и M0, использует логистическую регрессию. После стандартизации признаков z_t на обучающей части выборки вероятность неблагоприятного исхода параметризуется сигмой:

$$\hat{p}_t = \sigma(\beta_0 + \beta^\top z_t), \quad \sigma(u) = \frac{1}{1 + e^{-u}}.$$

Оценка параметров β выполняется минимизацией функционала:

$$\mathcal{L}(\beta) = - \sum_{i \in \text{train}} [Y_i \log p_i + (1 - Y_i) \log(1 - p_i)] + \lambda \|\beta\|_2^2.$$

Реализация опирается на `SGDClassifier` из библиотеки `scikit-learn` с логистической функцией потерь, L_2 -регуляризацией, стандартизатором `StandardScaler`, усреднением коэффициентов и генератором случайных чисел.

Заметим, что вложенные временные окна порождают корреляцию признаков на соседних масштабах, так как сглаженные поля наследуют часть информации с меньших окон. В этих условиях отсутствие регуляризации появляется большой риск переобучения. Конечно, введение регуляризации уменьшает дисперсию и улучшает обобщающую способность, но при этом, например, при рассмотрении значения β при признаке согласованного потока на масштабе B необходимо учитывать коррелированность этого признака.

В секундной реализации (REAL-05) кандидаты $\{10^{-5}, 10^{-4}, 10^{-3}\}$ сравниваются по средней дневной AP, и для всех трёх моделей итогового эксперимента выбран $\alpha = 10^{-3}$. После выбора гиперпараметра модель и стандартизатор переоцениваются на объединении обучающей и проверочной выборок.

7 Временная проверка и метрики

Основной протокол не перемешивает отдельные наблюдения между календарными периодами. Для сравнения M1 с M0 событийная реализация использовала интервалы: обучение 06.01.2025–15.01.2025, проверка 16.01.2025–19.01.2025, тест 20.01.2025–26.01.2025.

Рассчитываются ROC-AUC, Average Precision (AP), показатель Брайера и подъём доли положительного класса в верхних 10% прогнозов. Неопределённость разности (AP) оценивается повторной выборкой календарных дней с возвращением (5000 бутстрап-повторений), доверительный интервал отражает вариацию между днями, но при семи тестовых днях его следует считать ограниченной оценкой устойчивости, а не асимптотическим выводом.

8 Результаты сравнения с M0

В таблице 1 приведены результаты событийной реализации M1 против M0 на тесте REAL-02. Для обоих рынков и обоих горизонтов разность дневной AP положительна во все семь тестовых дней.

Таблица 1: Разность дневной AP ($M1 - M0$) на тесте REAL-02.

Рынок	H , с	средняя ΔAP	95% бутстрап-интервал
BTCUSDT	1	0.01960	[0.01423; 0.02484]
BTCUSDT	5	0.01727	[0.01095; 0.02406]
ETHUSDT	1	0.01827	[0.01272; 0.02353]
ETHUSDT	5	0.01106	[0.00597; 0.01647]

Данные подтверждают утверждение: многомасштабное представление потока ранжирует положительный знаковый маркаут на коротких горизонтах лучше, чем фиксированный масштаб $M0$. Результат не означает, что модель предсказывает среднесрочный курс, гарантирует реализованную прибыль или восстанавливает скрытое состояние конкретного маркет-мейкера. Секундная $M1$, зафиксированная в REAL-05, является базой для моделей $M2$ и $M3$; её абсолютные метрики занесены в реестр экспериментов и не должны механически сравниваться с событийной версией.

9 Ограничения и воспроизводимость

Модель $M1$ наследует все ограничения $M0$ и добавляет несколько собственных, связанных с многомасштабной структурой. Соседние масштабы используют значительную часть одних и тех же сделок; это порождает корреляцию признаков и требует осторожности при интерпретации индивидуальных коэффициентов. Фиксированная сетка $\mathcal{B}$ не обязана быть оптимальной для каждого рынка — равные по длительности временные окна могут содержать существенно разное число событий в зависимости от плотности потока.

Признаки разных масштабов объединяются аддитивно, явные производные или отношения по масштабу в модель не закладываются. Информационное множество по-прежнему ограничено одним рынком; состояние связанных торговых пар не используется. Модель решает задачу бинарной классификации и не различает движения по величине.

Исторические **aggTrades** не содержат книгу заявок, комиссию, принадлежность позиции и реальные издержки исполнения. Целевая переменная построена по будущему VWAP и пригодна для исследования ранжирования, но не тождественна чистому P&L. Семь тестовых дней недостаточны для утверждения об устойчивости во всех рыночных режимах.

Наконец, наличие нескольких масштабов не доказывает масштабную инвариантность и не является утверждением о существовании ренормгруппового потока на финансовом рынке.

Список литературы

- [1] L. R. Glosten, P. R. Milgrom. Bid, ask and transaction prices in a specialist market with heterogeneously informed traders. *Journal of Financial Economics*, 14(1), 71–100, 1985.

- [2] D. Easley, M. M. López de Prado, M. O'Hara. Flow toxicity and liquidity in a high-frequency world. *Review of Financial Studies*, 25(5), 1457–1493, 2012.
- [3] Binance. Spot REST API: Compressed/Aggregate Trades List. <https://developers.binance.com/en/docs/catalog/core-trading-spot-trading/api/rest-api/market>.
- [4] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.
- [5] Scikit-learn developers. SGDClassifier documentation. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html.
- [6] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.