

ReDataX

M2: Cross-Market Multiscale Model

Egor Vasilev

Содержание

1	Роль модели и проверяемая гипотеза	2
2	Мотивация межрыночного расширения	2
3	Источник данных и общая сетка	2
4	Система масштабов и укрупнение	3
5	Целевая переменная и маска наблюдений	3
6	Признаки и размерность M2	3
7	Статистическая модель и обучение	4
8	Временная проверка и метрики	5
9	Результаты	5
10	Ограничения и воспроизводимость	5

1 Роль модели и проверяемая гипотеза

M2 расширяет M1 многомасштабными состояниями связанных рынков. M1 описывает один рынок и потому не различает ситуации, в которых дисбаланс целевого рынка подкреплён или, напротив, ослаблен состоянием соседнего рынка. Цель M2 — построить совместное описание нескольких рынков и проверить, даёт ли оно прирост прогнозной точности.

Гипотеза 1.1. После учёта многомасштабного состояния $X_A(t)$ целевого рынка A синхронные состояния других рынков $X_{S \setminus A}(t)$ содержат дополнительную информацию о знаковом маркете, иными словами

$$\mathbb{P}(Y_{A,H}(t) = 1 \mid X_A(t), X_{S \setminus A}(t)) \neq \mathbb{P}(Y_{A,H}(t) = 1 \mid X_A(t)).$$

Сравнение M2 и M1 устроено аналогично - единственным отличием остаётся информационное множество $\mathcal{I}_t$. Целевой рынок, горизонт прогнозирования, множество допустимых наблюдений, алгоритм классификации, временные разбиения и способ расчёта метрик остаются неизменными, а значит, любой прирост качества может быть отнесён на счёт добавочной ценности межрыночной информации.

Название реализации `rg_no_j`, где смысл `_no_j` будет пояснен позже.

2 Мотивация межрыночного расширения

BTCUSDT и ETHUSDT не являются независимыми потоками. Оба рынка используют общую котируемую валюту USDT, реагируют на общие изменения ликвидности и могут отражать один и тот же импульс с разной задержкой и амплитудой. Это не означает, что один рынок определяет другой, но допускает, что состояние соседнего рынка несёт полезную информацию после того, как собственное многомасштабное состояние целевого рынка уже определено.

Работа мотивирована исследованиями рыночной микроструктуры, где направленный поток и дисбаланс связываются с последующим изменением цены [1, 3, 2].

3 Источник данных и общая сетка

Исходным источником служат агрегированные сделки Binance Spot (`aggTrades`) для рынков

$$\mathcal{S} = \{\text{BTCUSDT}, \text{ETHUSDT}, \text{ETHBTC}\}$$

Парсер ReDataX преобразует флаг `m` в знак агрессивной стороны $\varepsilon_k \in \{-1, +1\}$, после чего сделки агрегируются по целым секундам UTC.

Для каждого рынка $s \in \mathcal{S}$ и секунды t определяются объёмы агрессивных покупок $V_s^+(t)$, продаж $V_s^-(t)$ и средневзвешенная цена $P_s(t)$. Если сделок в секунду нет, объёмы равны нулю, а цена остаётся неопределённой.

Определение 3.1. Для рынка s в секунду t *полем потока* называется величина

$$\phi_s(t) = \begin{cases} \frac{V_s^+(t) - V_s^-(t)}{V_s^+(t) + V_s^-(t)}, & V_s^+(t) + V_s^-(t) > 0, \\ 0, & \text{в отсутствие сделок.} \end{cases}$$

Таким образом поле ϕ , которое имеет область значений $[-1, 1]$, описывает направленный поток сделок.

Замечание 3.1. Для ETHBTC котируемая валюта — BTC, тогда как для BTCUSDT и ETHUSDT — USDT. На безразмерное отношение ϕ_s это не влияет, однако текущий логарифм объёма ETHBTC имеет другие исходные единицы, как раз для этого применяется стандартизация.

4 Система масштабов и укрупнение

Семейство масштабов в ReDataX задается, как степени двойки:

$$\mathcal{B} = \{1, 2, 4, 8, 16, 32, 64\} \text{ секунд.}$$

Для каждого рынка s и масштаба $B \in \mathcal{B}$ вычисляется скользящее среднее по календарным секундам:

$$\bar{\phi}_s^{(B)}(t) = \frac{1}{B} \sum_{u=0}^{B-1} \phi_s(t-u),$$

включающее текущую завершённую секунду. Первые $B - 1$ секунд дня не имеют полного окна, поэтому общая выборка начинается не ранее 64-й секунды. Секунды без сделок сохраняются в знаменателе как нули.

5 Целевая переменная и маска наблюдений

Для целевого рынка $A \in \{\text{BTCUSDT}, \text{ETHUSDT}\}$ вводится ориентация $d_A(t) = \text{sign } \phi_A(t)$. Знаковый маркаут на горизонте H в базисных пунктах определяется как

$$m_{A,H}(t) = 10^4 d_A(t) \frac{P_A(t+H) - P_A(t)}{P_A(t)},$$

а бинарная метка принимает значение 1 при положительном маркауте:

$$Y_{A,H}(t) = \mathbb{1}\{m_{A,H}(t) > 0\}.$$

В финальном эксперименте горизонт H составил 5 секунд.

В общую маску M1, M2 и M3 входят только моменты, для которых выполнены четыре условия: прошло не менее 63 секунд с начала суток; целевой рынок активен в секунду t и $d_A(t) \neq 0$; VWAP целевого рынка конечен и положителен как в t , так и в $t + H$; момент $t + H$ не выходит за границу дня. Активность связанных рынков в текущую секунду не обязательна — их нулевой поток является допустимым состоянием.

6 Признаки и размерность M2

Для каждого рынка $s \in \mathcal{S}$, масштаба $B \in \mathcal{B}$ и текущей ориентации целевого рынка $d_A(t)$ строятся четыре преобразования поля.

Определение 6.1. *Согласованным потоком* рынка A будем называть величину

$$h_{s,B}^{(A)}(t) = d_A(t) \bar{\phi}_s^{(B)}(t).$$

Положительное значение означает, что поток рынка s на масштабе B сонаправлен с текущим направлением целевого рынка A .

Определение 6.2. Амплитуда дисбаланса и его чётные степени определяются как

$$r_{s,B}(t) = |\bar{\phi}_s^{(B)}(t)|, \quad a_{s,B}(t) = (\bar{\phi}_s^{(B)}(t))^2, \quad b_{s,B}(t) = (\bar{\phi}_s^{(B)}(t))^4.$$

Эти признаки позволяют линейной модели различать слабые и сильные дисбалансы.

Абсолютный размер текущей секунды фиксируется логарифмом совокупного номинала:

$$\ell_s(t) = \log(1 + V_s^+(t) + V_s^-(t)).$$

Итоговый вектор M2:

$$X_A^{\text{M2}}(t) = \left(\{\ell_s(t)\}_{s \in \mathcal{S}}, \{h_{s,B}^{(A)}, r_{s,B}, a_{s,B}, b_{s,B}\}_{s \in \mathcal{S}, B \in \mathcal{B}} \right).$$

Его размерность

$$\dim X^{\text{M2}} = |\mathcal{S}| + 4 |\mathcal{S}| |\mathcal{B}| = 3 + 4 \cdot 3 \cdot 7 = 87.$$

7 Статистическая модель и обучение

M2, как и предыдущие модели, использует логистическую регрессию. После стандартизации признаков $z_A^{\text{M2}}(t)$ на обучающей части выборки вероятность неблагоприятного исхода параметризуется сигмной:

$$\hat{p}_A(t) = \sigma \left(\beta_0 + \sum_{s \in \mathcal{S}} \beta_s^\top z_s(t) \right), \quad \sigma(u) = \frac{1}{1 + e^{-u}}.$$

Оценка параметров β выполняется минимизацией функционала:

$$\mathcal{L}(\beta) = - \sum_{i \in \text{train}} [Y_i \log p_i + (1 - Y_i) \log(1 - p_i)] + \lambda \|\beta\|_2^2.$$

Реализация строится на `SGDClassifier` с логистической функцией потерь, L_2 -регуляризацией, стандартизатором `StandardScaler`, усреднением коэффициентов и фиксированным `random_state`.

Регуляризация, аналогично M1, играет важную роль: помимо того, что вложенные временные окна порождают корреляции признаков на соседних масштабах, состояния BTCUSD и ETHUSD могут иметь общие рыночные факторы, усиливая коллинеарность.

Параметр α , обратный коэффициенту регуляризации, выбирается по средней дневной AP на периоде разработки из сетки $\{10^{-5}, 10^{-4}, 10^{-3}\}$. Для M2, как и для M1, выбран $\alpha = 10^{-3}$. После выбора модель и стандартизатор переоцениваются на объединении обучающей и проверочной выборок.

8 Временная проверка и метрики

Основной протокол не перемешивает отдельные наблюдения между календарными периодами. Эксперимент REAL-05 использует следующие временные части:

Обучение:	06.01.2025 – 19.01.2025,
Период разработки:	20.01.2025 – 26.01.2025,
Итоговый тест:	27.01.2025 – 02.02.2025.

Рассчитываются ROC-AUC, Average Precision (AP), показатель Брайера и подъём доли положительного класса в верхних 10% прогнозов. Главный операционный критерий — разность дневной AP между M2 и M1. Неопределённость этой разности оценивается повторной выборкой календарных дней с возвращением (5000 бутстрап-повторений). В таблицах «улучшение Брайера» определено как $\text{Brier}_{M1} - \text{Brier}_{M2}$, так что положительное значение соответствует меньшей квадратичной ошибке вероятности.

9 Результаты

В таблице 1 приведены средние дневные разности M2 минус M1 на итоговом тестовом периоде REAL-05A. Для обоих целевых рынков все четыре показателя улучшились во все семь тестовых дней.

Таблица 1: REAL-05A: средняя дневная разность M2 минус M1.

Рынок	Показатель	Разность	95% интервал
BTCUSDT	ROC-AUC	0.01452	[0.01238; 0.01696]
BTCUSDT	AP	0.01879	[0.01676; 0.02129]
BTCUSDT	улучшение Брайера	0.00301	[0.00210; 0.00388]
BTCUSDT	подъём верхнего дециля	0.06856	[0.05865; 0.07971]
ETHUSDT	ROC-AUC	0.00849	[0.00602; 0.01096]
ETHUSDT	AP	0.01120	[0.00892; 0.01385]
ETHUSDT	улучшение Брайера	0.00100	[0.00050; 0.00155]
ETHUSDT	подъём верхнего дециля	0.04268	[0.03438; 0.05305]

Объединённая AP выросла с 0.63155 до 0.64967 для BTCUSDT и с 0.63675 до 0.64763 для ETHUSDT. Данные поддерживают гипотезу о том, что синхронное межрыночное состояние содержит добавочную прогнозную информацию о знаковом маркете на проверенном коротком горизонте.

В рамках зафиксированного протокола M2 превосходит секундную M1 и является лучшей подтверждённой спецификацией среди M0–M3. Вывод относится к ранжированию знакового маркета на горизонте 5 секунд.

10 Ограничения и воспроизводимость

M2 наследует все ограничения M1 и добавляет несколько собственных. Наблюдательная связь между рынками не устанавливает направление причинности: оба

рынка могут откликаться на общий внешний фактор, создавая видимость информационной передачи там, где её нет. Синхронизация рынков неполна: публичные сделки имеют дискретные метки времени и не отражают реальные задержки получения данных торговой системой. Одинаковые по длительности временные окна могут содержать разное число событий на целевом и связанном рынках, что ограничивает сопоставимость масштабов.

Исторические `aggTrades` не содержат книгу заявок, комиссию, принадлежность позиции и реальные издержки исполнения. Нулевое заполнение неактивных секунд является частью определения поля; другая схема заполнения требует новой версии признаков. Семидневный итоговый период даёт сильное внутреннее сравнение, но не покрывает все рыночные режимы.

Признаки разных рынков рассчитываются, как сумма: одель не содержит членов вида $\phi^A \phi^B$ и не может уловить, что совместное появление двух сонаправленных сигналов опаснее суммы их изолированных эффектов, именно это означает `_no_j`, так как можно ввести слагаемое вида

$$J\phi_A\phi_B$$

которое будет отвечать взаимодействию рынков. Это сделано в модели M3.

Список литературы

- [1] L. R. Glosten, P. R. Milgrom. Bid, ask and transaction prices in a specialist market with heterogeneously informed traders. *Journal of Financial Economics*, 14(1), 71–100, 1985.
- [2] D. Easley, M. M. López de Prado, M. O’Hara. Flow toxicity and liquidity in a high-frequency world. *Review of Financial Studies*, 25(5), 1457–1493, 2012.
- [3] R. Cont, A. Kukanov, S. Stoikov. The price impact of order book events. *Journal of Financial Econometrics*, 12(1), 47–88, 2014.
- [4] L. P. Kadanoff. Scaling laws for Ising models near T_c . *Physics Physique Fizika*, 2, 263–272, 1966.
- [5] K. G. Wilson. Renormalization group and critical phenomena. I. *Physical Review B*, 4, 3174–3183, 1971.
- [6] Binance. Spot REST API: Compressed/Aggregate Trades List. <https://developers.binance.com/en/docs/catalog/core-trading-spot-trading/api/rest-api/market>.
- [7] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.
- [8] Scikit-learn developers. SGDClassifier documentation. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html.
- [9] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.