

ReDataX

M3: Cross-Market Multiscale Model With Interection Term

Egor Vasilev

Версия 1.0

Согласовано с веткой `main`, коммит [2d6affc](#)

Содержание

1	Роль модели и проверяемая гипотеза	2
2	Мотивация: почему М2 может быть недостаточно	2
3	Базовое состояние М2	3
4	Явные межрыночные взаимодействия	3
5	Статистическая модель и обучение	4
6	Экспериментальный протокол	4
7	Результаты	5
8	Ограничения и воспроизводимость	5

1 Роль модели и проверяемая гипотеза

М2 описывает каждый рынок отдельным набором признаков, и её логит аддитивен по входным столбцам: вклад состояния одного рынка не зависит от текущего состояния другого. В таком случае М3 построена для проверки гипотезы

Гипотеза 1.1. Совместные состояния рынков содержат информацию, не представляемую аддитивной функцией основных признаков М2. Иными словами, для целевого рынка A

$$\mathbb{P}(Y_{A,H} = 1 \mid X_A^{M2}, X^J) \neq \mathbb{P}(Y_{A,H} = 1 \mid X_A^{M2}),$$

где X^J — вектор попарных произведений полей.

Сравнение М3 и М2 устроено так, чтобы единственным отличием оставалось присутствие блока J . Целевой рынок, горизонт прогнозирования, множество допустимых наблюдений, алгоритм классификации, временные разбиения и способ расчёта метрик остаются неизменными, а значит, любой прирост или ухудшение качества можно отнести на счёт добавленных взаимодействий.

2 Мотивация: почему М2 может быть недостаточно

Логит М2 имеет вид

$$\eta_i^{M2} = \beta_0 + \beta_A^\top z_i^A + \beta_B^\top z_i^B,$$

где вклады двух рынков суммируются независимо. Модель способна одновременно повысить оценку риска при агрессивных покупках на целевом рынке и при агрессивных покупках на связанном, но не различает ситуации, в которых два сонаправленных потока усиливают риск сильнее, чем сумма их изолированных эффектов, а противоположно направленные потоки, напротив, сглаживают его.

Реальный поток сделок может иметь более сложную структуру: импульс на целевом рынке может быть опасен только при подтверждении связанным рынком; два одинаково направленных потока способны взаимно усиливать риск, а расходящиеся — указывать на шум или временное расхождение рынков. Взаимодействие может проявляться избирательно: только на коротких масштабах, где важна синхронность, или только на длинных, где накапливается общий фон. М2 не различает эти ситуации, и М3 построена для проверки их через произведения полей на совпадающих масштабах.

Идея введения взаимодействий пришла из известной задачи статфизики — модели Изинга. Здесь гамильтониан содержит сумму попарных произведений записывается как

$$H_{\text{interaction}} = \sum_{\langle i,j \rangle} J_{ij} s_i s_j,$$

где s_i и s_j — значения спинов в соседних узлах некоторой решётки, а J_{ij} — сила связи между ними. Если спины сонаправлены ($s_i s_j > 0$), вклад такой пары в энергию определяется знаком J_{ij} : при определенном типе взаимодействия общая энергия системы понижается, при другом — повышается. Ключевое свойство такой записи состоит в том, что эффект одного спина на систему не является постоянным — он зависит

от текущей ориентации соседа. В ReDataX эта запись используется как принцип построения признаков. Конечно, финансовый рынок не отождествляется с равновесной физической системой - это лишь соображения, которые легли в основу построения.

3 Базовое состояние М2

М3 надстраивается над М2 без изменения её признакового пространства. Исходные данные, система масштабов и целевая переменная полностью совпадают с финальным межрыночным экспериментом REAL-05. Итак, наблюдаются три рынка:

$$\mathcal{S} = \{\text{BTCUSDT}, \text{ETHUSDT}, \text{ETHBTC}\}$$

Секундное поле потока для рынка s определяется как

$$\phi_s(t) = \begin{cases} \frac{V_s^+(t) - V_s^-(t)}{V_s^+(t) + V_s^-(t)}, & \text{если объём положителен,} \\ 0, & \text{в отсутствие сделок.} \end{cases}$$

Сглаженное поле на масштабе $B \in \mathcal{B} = \{1, 2, 4, 8, 16, 32, 64\}$ секунд вычисляется как скользящее среднее

$$\bar{\phi}_s^{(B)}(t) = \frac{1}{B} \sum_{u=0}^{B-1} \phi_s(t-u).$$

Для целевого рынка $A \in \{\text{BTCUSDT}, \text{ETHUSDT}\}$ ориентация $d_A(t) = \text{sign } \phi_A(t)$ задаёт знаковый маркаут на горизонте $H = 5$ секунд:

$$m_{A,H}(t) = 10^4 d_A(t) \frac{P_A(t+H) - P_A(t)}{P_A(t)}, \quad Y_{A,H}(t) = \mathbf{1}\{m_{A,H}(t) > 0\}.$$

Базовый вектор М2 содержит 87 признаков: три текущих логарифма объёма $\ell_s(t) = \log(1 + V_s^+ + V_s^-)$ и четыре преобразования сглаженного поля для каждого рынка и каждого масштаба — согласованный поток $h_{s,B}^{(A)} = d_A \bar{\phi}_s^{(B)}$, амплитуду $r_{s,B} = |\bar{\phi}_s^{(B)}|$, квадрат $a_{s,B} = (\bar{\phi}_s^{(B)})^2$ и четвертую степень $b_{s,B} = (\bar{\phi}_s^{(B)})^4$.

4 Явные межрыночные взаимодействия

Определение 4.1. Для неупорядоченной пары различных рынков $s \neq r$ и масштаба $B \in \mathcal{B}$ признак попарного взаимодействия определяется как

$$j_{sr,B}(t) = \bar{\phi}_s^{(B)}(t) \bar{\phi}_r^{(B)}(t).$$

Положительное значение соответствует сонаправленным потокам, отрицательное — противоположно направленным. Абсолютная величина растёт при совместно сильных дисбалансах.

Реализация использует три неупорядоченные пары:

$$\mathcal{P} = \{(\text{BTCUSDT}, \text{ETHUSDT}), (\text{BTCUSDT}, \text{ETHBTC}), (\text{ETHUSDT}, \text{ETHBTC})\}.$$

Для каждой пары перемножаются поля только на совпадающих масштабах; полная матрица 7×7 межмасштабных произведений не строится. Число новых признаков равно

$$\dim X^J = |\mathcal{P}| \cdot |\mathcal{B}| = 3 \cdot 7 = 21,$$

а итоговая размерность модели

$$\dim X^{\text{M3}} = 87 + 21 = 108.$$

В коде `build_feature_matrices()` взаимодействие вычисляется как произведение полей, предварительно умноженных на знак целевого потока. Поскольку $d_A^2 = 1$ на всех допустимых наблюдениях, итоговый признак не зависит от того, какой рынок выбран целевым:

$$[d_A \bar{\phi}_s^{(B)}] [d_A \bar{\phi}_r^{(B)}] = \bar{\phi}_s^{(B)} \bar{\phi}_r^{(B)}.$$

Различие между направлениями ($\text{BTCUSDT} \leftarrow \text{ETHUSDT}$ и $\text{ETHUSDT} \leftarrow \text{BTCUSDT}$) возникает только за счёт разных меток и, как следствие, разных оценённых коэффициентов.

5 Статистическая модель и обучение

М3 сохраняет все 87 признаков М2 и добавляет к ним 21 взаимодействие. Логистическая регрессия, как и в предыдущих моделях, параметризует вероятность сигмоидой:

$$\hat{p}_A(t) = \sigma(\eta_A^{\text{M3}}(t)), \quad \eta_A^{\text{M3}}(t) = \beta_0 + \beta^\top z_A^{\text{M2}}(t) + \sum_{(s,r) \in \mathcal{P}} \sum_{B \in \mathcal{B}} \gamma_{sr,B} z_{sr,B}(t),$$

где $z_{sr,B}$ — стандартизованное взаимодействие $j_{sr,B}$, а $\gamma_{sr,B}$ — соответствующий коэффициент (в коде обозначается $J[s, r, B]$). Параметры модели оцениваются минимизацией функционала:

$$\mathcal{L}(\beta, \gamma) = - \sum_{i \in \text{train}} [Y_i \log p_i + (1 - Y_i) \log(1 - p_i)] + \lambda (\|\beta\|_2^2 + \|\gamma\|_2^2).$$

Реализация использует `SGDClassifier` с логистической потерей, L_2 -регуляризацией, усреднением коэффициентов и отдельным `StandardScaler` для каждого классификатора. Параметр регуляризации α выбирается по средней дневной AP на периоде разработки из сетки $\{10^{-5}, 10^{-4}, 10^{-3}\}$; для М3, как и для М2, выбран $\alpha = 10^{-3}$. После выбора гиперпараметра модель переоценивается на объединении обучающей и проверочной выборки.

6 Экспериментальный протокол

Эксперимент REAL-05 использует следующие временные части:

Обучение:	06.01.2025 – 19.01.2025,
Период разработки:	20.01.2025 – 26.01.2025,
Итоговый тест:	27.01.2025 – 02.02.2025.

М2 и М3 получают идентичные строки итогового теста. Основными показателями: ROC-AUC, Average Precision (AP), показатель Брайера и подъём доли положительного класса в верхних 10% прогнозов. Главный критерий — разность дневной AP между М3 и М2. Неопределённость оценивается повторной выборкой семи тестовых дней с возвращением (5000 бутстрап-повторений). “положительный Брайер” предельно как $\text{Brier}_{M2} - \text{Brier}_{M3}$.

7 Результаты

В таблице 1 приведены средние дневные разности М3 минус М2 на итоговом тестовом периоде REAL-05B.

Таблица 1: REAL-05B: средняя дневная разность М3 минус М2.

Рынок	Показатель	Разность	95% бутстрап-интервал
BTCUSDT	ROC-AUC	-0.000075	[-0.000191; 0.000018]
BTCUSDT	AP	0.000259	[0.000113; 0.000396]
BTCUSDT	улучшение Брайера	-0.000057	[-0.000173; 0.000056]
BTCUSDT	подъём верхнего дециля	0.000382	[-0.001617; 0.002497]
ETHUSDT	ROC-AUC	-0.000284	[-0.000471; -0.000096]
ETHUSDT	AP	-0.000229	[-0.000428; -0.000032]
ETHUSDT	улучшение Брайера	-0.000132	[-0.000196; -0.000077]
ETHUSDT	подъём верхнего дециля	-0.000257	[-0.001045; 0.000810]

Для BTCUSDT средняя дневная AP возросла на 0.000259 и была положительной в шести из семи дней, однако ROC-AUC и показатель Брайера не улучшились, а доверительный интервал подъёма верхнего дециля включает ноль. Масштаб эффекта AP примерно на два порядка меньше улучшения М2 относительно М1. Для ETHUSDT М3 ухудшила ROC-AUC, AP и показатель Брайера; положительная разность AP наблюдалась лишь в одном тестовом дне.

Универсальная добавочная ценность явных попарных взаимодействий не подтверждена. Малый частный эффект для BTCUSDT не компенсирует отсутствия согласованности показателей и ухудшения на ETHUSDT. М3 отклонена как общая итоговая модель, а М2 без J сохранена как финальная.

8 Ограничения и воспроизводимость

М3 наследует все ограничения М0–М2 и добавляет ряд своих. Наблюдаемая согласованность потоков не доказывает влияния одного рынка на другой: общий внешний фактор может одновременно изменять оба потока, создавая видимость взаимодействия. Форма взаимодействия задана заранее — билинейное произведение на совпадающих масштабах — и не охватывает другие возможные нелинейности или связи между разными масштабами. Коэффициенты $\gamma_{sr,B}$ коррелированы из-за вложенности окон и L_2 -регуляризации, что исключает их независимую интерпретацию. Семидневный итоговый период ограничивает переносимость вывода на другие рыночные режимы. Проверены только пары одинаковых масштабов. Данные `aggTrades`

не содержат книгу заявок, инвентарь платформы и реальные издержки исполнения. Результат относится к наблюдаемому потоку и маркауту на горизонте 5 секунд; перенос на более длинные горизонты требует отдельного исследования.

Список литературы

- [1] E. Ising. Beitrag zur Theorie des Ferromagnetismus. *Zeitschrift für Physik*, 31, 253–258, 1925.
- [2] L. P. Kadanoff. Scaling laws for Ising models near T_c . *Physics Physique Fizika*, 2, 263–272, 1966.
- [3] L. R. Glosten, P. R. Milgrom. Bid, ask and transaction prices in a specialist market with heterogeneously informed traders. *Journal of Financial Economics*, 14(1), 71–100, 1985.
- [4] D. Easley, M. M. López de Prado, M. O’Hara. Flow toxicity and liquidity in a high-frequency world. *Review of Financial Studies*, 25(5), 1457–1493, 2012.
- [5] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.
- [6] Scikit-learn developers. SGDClassifier documentation. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html.
- [7] B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1994.